

Desafío Académico: Modelado y Resolución de Sistemas Lineales Complejos

Optimización y Análisis de Estabilidad en el Entrenamiento de Modelos de Inteligencia Artificial

Resumen

El presente trabajo aborda la resolución numérica de sistemas de ecuaciones lineales aplicados al entrenamiento de modelos de Inteligencia Artificial. Mediante el modelado de tres escenarios de estrés de datos (Ideal, Masivo y Multicolinealidad), se evalúa la estabilidad algorítmica. Se demuestra matemáticamente y a través de un simulador web interactivo desarrollado en Python, cómo la matriz mal condicionada provoca el colapso de métodos iterativos clásicos y cómo el algoritmo de Gradiente Conjugado Precondicionado estabiliza el sistema, optimizando el consumo de recursos computacionales.

1 Introducción y Contexto

El presente documento modela el proceso de entrenamiento de un algoritmo de Inteligencia Artificial (específicamente, un modelo de regresión múltiple para análisis de sentimientos) orientado a evaluar texto extraído de bases de datos relacionales.

En el aprendizaje automático, para encontrar los pesos óptimos que minimizan el error de predicción, el sistema debe resolver un sistema de ecuaciones lineales simultáneas conocido como las **Ecuaciones Normales** ($Ax = b$). En este modelo, evaluaremos la estabilidad y eficiencia de diversos algoritmos de resolución numérica frente a escenarios críticos de extracción masiva de datos y problemas estadísticos como la multicolinealidad.

2 Fase 1: El Desafío y Modelado del Sistema

2.1 Definición de Variables (x_n) y Término Independiente (b)

En el contexto del modelado predictivo, la matriz A representa la matriz de covarianza de las frecuencias de palabras procesadas, y el vector x contiene los pesos (weights) que la IA debe aprender para realizar su predicción.

- x_1 : Peso matemático de influencia asignado a palabras claramente positivas (ej. “excelente”, “logro”).

- x_2 : Peso matemático de influencia asignado a palabras ambiguas o neutrales (ej. “bueno”, “aceptable”).
- x_3 : Peso matemático de influencia asignado a palabras negativas o de toxicidad (ej. “pésimo”, “error”).
- **Término independiente (b)**: Representa el vector de correlación con la variable objetivo (el estado emocional real a predecir).

2.2 Caso Ideal: Datos Estadísticamente Independientes

El conjunto de datos de entrenamiento es claro y las variables predictoras no se solapan. La matriz de covarianza resultante es consistente, bien condicionada y fuertemente diagonal dominante. Esto garantiza que los algoritmos iterativos clásicos converjan rápidamente.

$$A_{ideal} = \begin{bmatrix} 15 & 2 & 1 \\ 2 & 10 & 1 \\ 1 & 1 & 12 \end{bmatrix}, \quad b_{ideal} = \begin{bmatrix} 45 \\ 30 \\ 25 \end{bmatrix} \quad (1)$$

2.3 Caso Bajo Estrés: Entrenamiento Masivo

Este escenario simula la inyección de millones de registros extraídos tras un evento viral en redes sociales. Las proporciones estadísticas se mantienen, pero la magnitud de los coeficientes aumenta drásticamente, exigiendo una alta estabilidad en el procesamiento de punto flotante de los algoritmos.

$$A_{estres} = \begin{bmatrix} 1,5 \cdot 10^6 & 2 \cdot 10^5 & 10^5 \\ 2 \cdot 10^5 & 10^6 & 10^5 \\ 10^5 & 10^5 & 1,2 \cdot 10^6 \end{bmatrix}, \quad b_{estres} = \begin{bmatrix} 4,5 \cdot 10^6 \\ 3 \cdot 10^6 \\ 2,5 \cdot 10^6 \end{bmatrix} \quad (2)$$

2.4 Caso Mal Condicionado: Multicolinealidad

Se presenta una falla en la limpieza del *dataset*, introduciendo al modelo dos variables que son sinónimos casi exactos (por ejemplo, contar palabras “felices” y palabras “alegres” de forma separada). Esto genera multicolinealidad, traducándose matemáticamente en filas casi linealmente dependientes (hiperplanos casi paralelos) que dificultan severamente la convergencia y justifican la necesidad de utilizar un preconditionador.

$$A_{mal} = \begin{bmatrix} 1 & 1 & 0,1 \\ 1 & 1,0001 & 0,1 \\ 0,1 & 0,1 & 2 \end{bmatrix}, \quad b_{mal} = \begin{bmatrix} 10 \\ 10,001 \\ 5 \end{bmatrix} \quad (3)$$

3 Fase 2: Rigor Matemático y Análisis Teórico

Para evaluar correctamente la precisión y la tasa de convergencia de los métodos iterativos, es imprescindible calcular previamente la solución teórica (exacta) de los tres escenarios modelados. Asimismo, se analizará el número de condición de las matrices involucradas, el cual determina la estabilidad numérica del sistema.

3.1 Soluciones Teóricas Exactas

Resolviendo los sistemas mediante métodos algebraicos directos (eliminación gaussiana exacta o regla de Cramer), obtenemos los vectores solución óptimos.

1. Solución del Caso Ideal y Caso Bajo Estrés:

Dado que el *Caso Bajo Estrés* es un múltiplo escalar (10^5) del *Caso Ideal*, la solución geométrica de la intersección de los planos es idéntica en ambos escenarios. Esto permite aislar y evaluar exclusivamente cómo la magnitud extrema de los coeficientes afecta el error de acarreo por redondeo computacional.

$$x_{ideal} = x_{estres} = \begin{bmatrix} \frac{4465}{1731} \\ \frac{4010}{1731} \\ \frac{2900}{1731} \end{bmatrix} \approx \begin{bmatrix} 2,5794 \\ 2,3165 \\ 1,6753 \end{bmatrix} \quad (4)$$

2. Solución del Caso Mal Condicionado:

A pesar de la casi dependencia lineal entre la primera y segunda ecuación, el sistema posee una solución única resolviendo algebraicamente:

$$x_{mal} = \begin{bmatrix} -\frac{40}{199} \\ 10 \\ \frac{400}{199} \end{bmatrix} \approx \begin{bmatrix} -0,2010 \\ 10,0000 \\ 2,0100 \end{bmatrix} \quad (5)$$

3.2 Análisis del Número de Condición $\kappa(A)$

La convergencia y precisión de las secuencias generadas por métodos iterativos dependen fundamentalmente del número de condición de la matriz de coeficientes A . Si consideramos λ_n y λ_1 como el mayor y menor autovalor de la matriz simétrica A , respectivamente, el número de condición respecto a la norma euclidiana está dado por:

$$\kappa(A) = \frac{\lambda_n}{\lambda_1} \quad (6)$$

En el **Caso Ideal**, los autovalores están relativamente agrupados, resultando en un $\kappa(A)$ cercano a 1, lo que garantiza una convergencia lineal rápida y estable.

Por el contrario, en el **Caso Mal Condicionado**, la multicolinealidad provoca que uno de los autovalores tienda a cero ($\lambda_1 \approx 0$). Esto dispara el valor de $\kappa(A)$ hacia el infinito. Como indica la teoría de gradientes conjugados, cuando la matriz es mal condicionada, la tasa de convergencia decae significativamente.

Para resolver este obstáculo computacional en la Fase 3, será imperativo transformar el sistema $Ax = b$ en un sistema equivalente preconditionado $Mx = \tilde{b}$ utilizando una matriz C no singular para estabilizar el espectro de autovalores y forzar la convergencia.

4 Fase 3: Implementación de Algoritmos Computacionales

Para la resolución de los sistemas modelados, se implementaron rutinas numéricas en Python. El objetivo es contrastar la robustez de los métodos directos e iterativos clásicos frente a algoritmos avanzados diseñados para sistemas complejos.

4.1 Métodos Clásicos y Directos

- **Factorización LU:** Como método directo, descompone la matriz A en el producto de una matriz triangular inferior (L) y una superior (U). Aunque es exacto y no sufre por el mal condicionamiento en la misma medida que los iterativos, su costo computacional $O(n^3)$ lo hace ineficiente para sistemas masivos.
- **Jacobi y Gauss-Seidel:** Métodos iterativos clásicos. Dependen fuertemente de que la matriz sea diagonalmente dominante.
- **SOR (Sobrerelajación Sucesiva):** Introduce un factor de relajación ω para acelerar la convergencia de Gauss-Seidel, útil en sistemas bien condicionados.

4.2 Gradiente Conjugado Precondicionado (GCP)

Para mitigar el colapso de los métodos iterativos en el escenario de multicolinealidad, se implementó el **Algoritmo Mz** (Gradiente Conjugado Precondicionado). Este algoritmo resuelve el sistema equivalente $Mx = \tilde{b}$ minimizando una función cuadrática en direcciones conjugadas. Para la implementación, se utilizó un preconditionador de Jacobi trivial $M = \text{diag}(A)$, el cual computacionalmente es económico y logra concentrar los autovalores de la nueva matriz, mejorando drásticamente su número de condición κ .

5 Fase 4: Análisis de Resultados y Desempeño

Se ejecutaron los algoritmos con una tolerancia estricta de 10^{-6} . Los resultados computacionales validan la teoría de estabilidad numérica frente a matrices mal condicionadas.

5.1 Tabla Comparativa de Eficiencia

El siguiente cuadro resume el comportamiento de los métodos. Las ejecuciones que superaron el límite de iteraciones sin alcanzar la tolerancia se marcan como fallidas (S/N = No converge).

Método	Iter. (Ideal)	Iter. (Stress)	Iter. (Mal C.)	Conv. (S/N)
Jacobi	12	12	> 50000	S / S / N
Gauss-Seidel	8	8	> 50000	S / S / N
SOR ($\omega = 1,1$)	6	6	> 50000	S / S / N
Grad. Conj. Prec.	3	3	3	S / S / S
Factorización LU	Directo	Directo	Directo	S / S / S

Cuadro 1: Comparativa de eficiencia de los métodos (Tolerancia 10^{-6})

5.2 Interpretación Técnica del Colapso Computacional

1. El impacto de la Multicolinealidad: En el *Caso Mal Condicionado*, la casi dependencia lineal entre las filas genera hiperplanos casi paralelos en el espacio tridimensional. Al ejecutar los métodos de Jacobi, Gauss-Seidel y SOR, la secuencia de aproximaciones oscila interminablemente entre estos planos sin poder anclarse en la intersección

exacta. La prueba empírica demostró que incluso tras 50,000 iteraciones, Jacobi no logra reducir el error residual por debajo de la tolerancia exigida.

2. La eficiencia del Precondicionador: El Gradiente Conjugado clásico sufre cuando λ_n (autovalor máximo) y λ_1 (autovalor mínimo) están muy separados. Al aplicar el preconditionador diagonal C en el Algoritmo GCP, transformamos el sistema. Como se evidencia en la Tabla 1, el algoritmo preconditionado ignoró por completo la inestabilidad de la matriz y encontró el minimizador global estricto en exactamente 3 iteraciones (coincidiendo teóricamente con la dimensión $n = 3$ del sistema), demostrando una superioridad absoluta frente a las métricas clásicas.

6 Fase 5: Innovación y Visualización Interactiva

Para complementar el rigor matemático y ofrecer una herramienta de análisis en tiempo real, se desarrolló un simulador web interactivo utilizando las bibliotecas **Streamlit** y **Plotly** en Python.

6.1 Arquitectura del Dashboard

La interfaz gráfica permite al usuario alternar dinámicamente entre los tres escenarios modelados. Al seleccionar un escenario, el *backend* ejecuta simultáneamente el método iterativo clásico (Jacobi) y el avanzado (GCP), mostrando métricas de convergencia instantáneas para su análisis comparativo directo.

6.2 Renderizado Tridimensional de Hiperplanos

La innovación principal radica en la representación gráfica del sistema lineal. Cada ecuación del sistema se grafica como un plano en el espacio tridimensional. Esta visualización es fundamental para comprender empíricamente el concepto de multicolinealidad:

- En el **Caso Ideal y de Estrés**, los tres planos se intersectan en un único punto claramente definido, permitiendo a los algoritmos encontrar el vector solución de manera eficiente.
- En el **Caso Mal Condicionado**, la visualización 3D revela de manera evidente que dos de los planos (representando las variables colineales) son hiperplanos casi paralelos, superponiéndose visualmente. Esto demuestra geométricamente por qué los algoritmos de relajación clásicos oscilan sin fin y fallan en encontrar el minimizador exacto.




Figura 1: Interfaz del Simulador Web: Resolución de algoritmos y visualización tridimensional interactiva de la colisión de hiperplanos.

7 Conclusión

El presente proyecto demuestra la importancia vital del análisis numérico en el desarrollo de software y en el procesamiento de datos masivos. Se comprobó empíricamente que, frente a matrices mal condicionadas por fenómenos como la multicolinealidad, los métodos iterativos clásicos colapsan, lo que en un entorno de producción real representaría una falla crítica del servidor. Sin embargo, la aplicación matemática de una matriz preconditionadora junto al método de Gradientes Conjugados garantiza la estabilidad del sistema, logrando una convergencia óptima y asegurando la integridad del ecosistema tecnológico.